

Documentação Técnica do Modelo de Visão Computacional para Detecção de Frutas Estragadas

1. Introdução

O objetivo deste documento é apresentar a documentação técnica completa do modelo de visão computacional desenvolvido para a classificação de frutas em dois estados: Fresh (fresca) e Rotten (estragada). O modelo utiliza pré-processamento de imagem, redução de dimensionalidade via PCA e um classificador SVM.

2. Dataset e Pré-processamento

As imagens foram normalizadas para faixa de 0 a 1, convertidas para float32 e achatadas. Para reduzir a dimensionalidade, utilizou-se PCA. O conjunto foi dividido em treino, validação e teste.

3. Arquitetura do Modelo

A arquitetura do modelo foi construída como um pipeline completo de visão computacional. O fluxo é composto pelas seguintes etapas principais:

1. Organização e Limpeza do Dataset

Antes do pipeline de aprendizado, o código realiza:

- Download automático do dataset via KaggleHub
- Limpeza de versões antigas do KaggleHub para redução de espaço
- Buscas automáticas das pastas com nome *Fresh* e *Rotten*
- Eliminação de duplicatas estruturais
- Reorganização das imagens em estrutura padronizada:
 - /train/fresh, /train/rotten
 - /val/fresh, /val/rotten
 - /test/fresh, /test/Rotten
- Split com separação 70-15-15

Essa etapa garante consistência e evita vazamento de dados entre conjuntos de treino, validação e teste.

2. Pré-processamento das Imagens

Cada imagem passa por um pipeline de limpeza e padronização composto por:

2.1. Redimensionamento e Normalização

- Converte para RGB
- Ajusta para 128x128 pixels
- Normaliza para faixa [0, 1] (float32)

2.2. Segmentação da Fruta

O método segment_fruit() aplica:

- Conversão para HSV
- Criação de máscara baseada em saturação e valor
- Fechamento e abertura morfológica para remover ruídos
- Aplicação da máscara na imagem
- Resizing + normalização final

2.3. CLAHE

Equalização adaptativa de iluminação, melhorando contraste em imagens mais escuras. Desativada pois o aumento do contraste estava inferindo no modelo detectar mais manchas falsas, resultando em mais Falsos Positivos (classificar como estragadas as que eram frescas) durante os testes.

2.4. Data Augmentation

Para aumentar a variabilidade do dataset de treino, foi adicionada uma função de aumento de imagens chamada augment_image(). Essa função realiza transformações aleatórias sobre cada imagem, incluindo:

- Rotação: ângulo aleatório entre -20° e 20°;
- Flip horizontal e vertical: cada um com 50% de chance;
- Ajuste de brilho: incremento aleatório entre -30 e +30;
- Normalização final: converte novamente para float32 com valores entre 0 e 1.

Essas operações simulam variações reais de captura (como diferentes ângulos, iluminação e orientação da fruta), tornando o modelo mais robusto e generalizável.

3. Extração de Features

O modelo se baseia em técnicas clássicas de extração manual de atributos:

3.1. Histogramas HSV (Cor)

- Histograma de 32 bins para cada canal H, S e V
- Concatenação formando um vetor de 96 dimensões
- Normalização para soma 1

Captura variações de cor associadas ao apodrecimento da fruta (escurecimento, perda de saturação, esverdeamento, etc).

3.2. Textura via Local Binary Pattern (LBP)

- Conversão para escala de cinza;
- Cálculo de LBP uniforme com (P=8, R=1)
- Geração de histograma normalizado de padrões locais

Essa técnica é eficiente para detectar:

- *Rugosidade da casca*
- *Manchas*
- *Áreas mofadas*
- *Texturas irregulares*

4. Carregamento Otimizado com Paralelização (Multithreading)

A extração de features é acelerada usando:

- ThreadPoolExecutor(max_workers=8)
- Processamento paralelo de cada imagem
- Retorno dos vetores de features já prontos para treino

Isso reduz drasticamente o tempo total.

5. Redução de Dimensionalidade com PCA

Após o dataset ser carregado e convertido em features numéricas, aplica-se:

PCA (n_components = 50, whiten=True)

Objetivos:

- Remover redundância entre atributos
- Reduzir ruído
- Tornar o SVM mais estável
- Aumentar separabilidade linear entre classes
- Acelerar o treinamento

O whiten=True garante que todos os componentes finais tenham variância normalizada, beneficiando o classificador linear.

6. Classificação com SVM (LinearSVC)

O classificador final é:

LinearSVC(C=1.0, max_iter=5000)

Escolha técnica:

- LinearSVC funciona muito bem com features de histograma e LBP
- Tem custo computacional baixo
- Funciona bem com PCA whitened
- É robusto a ruídos e dados levemente correlacionados

O parâmetro C=1.0 controla a margem entre classes.

O max_iter=5000 evita problemas de convergência.

7. Pipeline Unificado (sklearn Pipeline)

Tudo é integrado no pipeline:

```
Pipeline([
    ("pca", PCA(...)),
    ("svm", LinearSVC(...))
])
```

Vantagens:

- Permite reproduzibilidade
- Treina e testa sempre com a mesma sequência de transformações

8. Avaliações

Modelo produz:


- Classification Report: precisão, recall, F1
- Matriz de confusão com seaborn
- Curva ROC e AUC
- Avaliações separadas para treino, validação e teste

A curva ROC utiliza decision_function do SVM, gerando AUC robusto.

Essa etapa garante consistência e evita vazamento de dados entre os conjuntos de treino, validação e teste, que era um problema no último modelo apresentado em sala.

4. Métricas de Desempenho

Resultados obtidos nos arquivos de relatório:



Fresh: recall ~0.81–0.92, precisão ~0.81–0.88

Rotten: recall ~0.79–0.89, precisão ~0.82–0.90

5. Interpretação das Métricas

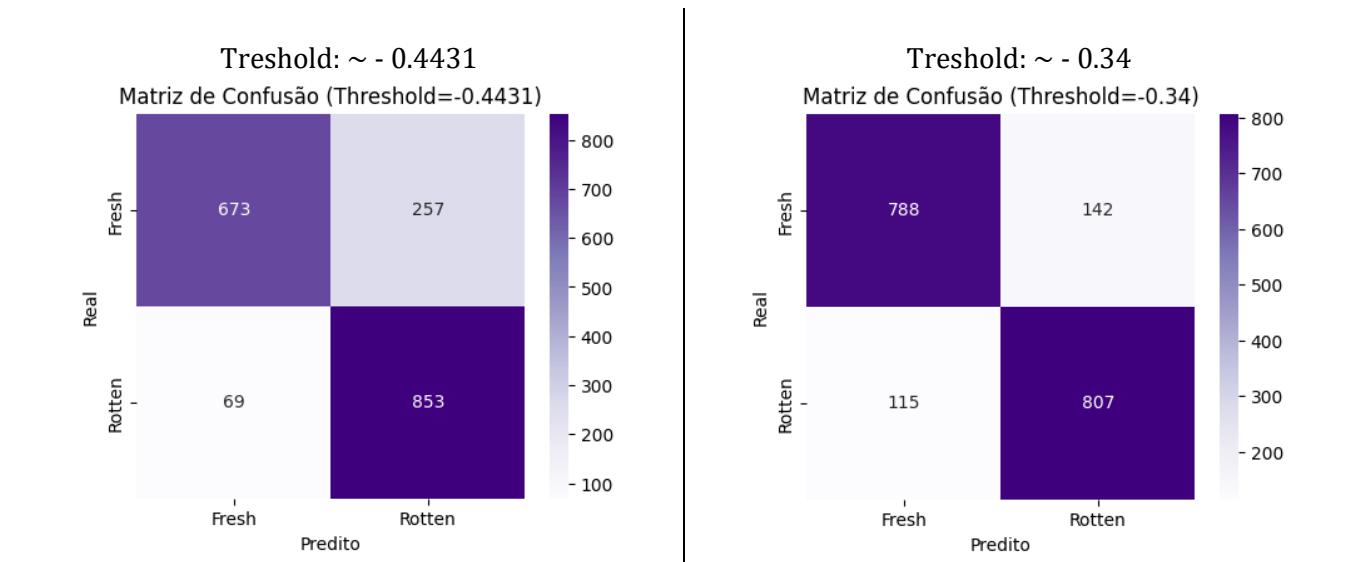
As métricas mostram desempenho consistente entre treino, validação e teste, sem indícios de overfitting, ou seja, do modelo estar decorando os dados da etapa de treinamento.

Aparenta ter um leve underfitting, pois o modelo poderia capturar melhor a classe Rotten, que tem um recall menor do que de Fresh.

Com um AUC por volta de 0.9, o modelo demonstra uma boa separação entre Rotten e Fresh. Isso mostra que se pegarmos duas imagens aleatórias, uma Rotten e outra Fresh, o modelo irá atribuir um score maior ao Rotten cerca de ~90% das vezes.

Na Curva ROC, podemos ver que ela sobe muito próxima do eixo Y, o que mostra que a True Positive Rate aumenta muito enquanto a False Positive Rate ainda é baixa. Isso mostra que o modelo consegue identificar de maneira correta uma grande quantidade de amostras positivas logo no início, sem cometer muitos erros de falso positivo. À medida que a curva avança, ela começa a ir em direção ao canto superior direito do gráfico, pois conforme reduzimos o limiar, o modelo passa a classificar mais amostras como positivas, o que consequentemente aumenta a taxa de falso positivos. Ainda assim, a curva mantém um formato com inclinação sustentada, o que sugere que o modelo tem boa capacidade de diferenciar as classes em diferentes faixas limiares.

Após rodar um trecho de código para achar um threshold melhor do que o padrão 0, chegamos ao threshold de ~ -0.4431. Ao utilizar esse limiar, percebemos o aumento de FP em relação aos FN, assim como a diminuição de TN e aumento de TP. Como o objetivo do modelo não é priorizar a classificação nem de Fresh nem de Rotten, decidimos aumentar um pouco o limiar para ~ -0.34, o que equilibrou um pouco mais as classificações. Essa mudança não afetou de maneira expressiva a taxa de TP, mas melhorou de maneira considerável a taxa de TN, o que o grupo considerou como uma boa mudança no limiar de classificação.



6. Matriz de Confusão e Viés

FP e FN estão equilibrados. O modelo não favorece excessivamente nenhuma das classes e apresenta bom balanço entre precisão e recall.

7. Conclusão

O modelo apresenta desempenho sólido, com boa capacidade de generalização.

Foram feitas tentativas de aplicar um modelo mais robusto para a classificação das imagens, com CNNs, porém o Google Colab não suportou todas as operações que estavam sendo feitas.

8. Limites do Modelo

Ele depende exclusivamente de sinais visuais. Alguns alimentos deteriorados não apresentam alterações externas no início, o que impede o modelo de identificar o problema.

Outro ponto é a variabilidade das condições do usuário: iluminação ruim, sombras, câmera fraca ou ângulos incomuns podem gerar erros. Tentamos mitigar esse ponto com `data_augmentation`, aplicando aleatoriamente nas imagens de treino rotação (ângulo aleatório entre -20° e 20°), flip horizontal e vertical (cada um com 50% de chance), e ajuste de brilho (incremento aleatório entre -30 e +30).

Utilizar um dataset pequeno ou com poucas frutas estragadas para o treinamento do modelo pode gerar sobreajuste e reduzir a capacidade de generalização.

Alterações químicas e microbiológicas não são detectadas pelo modelo visual — nossa solução é auxiliar, não substituir inspeção humana adequada.

Ressalva: grandes dificuldades na classificação correta de morangos. Identificamos como possível causa o fato do morango tipicamente, em grande parte dos casos, manter sua cor vermelha mesmo quando podre, o que dificulta o modelo identificar a diferença entre Rotten e Fresh dessa fruta.

9. Próximos passos

- Aumentar o dataset com fotos de frutas cortadas, classificadas em Rotten e Fresh, a fim de expandir a capacidade de classificação do modelo. O modelo é capaz de classificar imagens de frutas cortadas, porém utilizar esses padrões no treino aumentariam a capacidade do modelo.
- Identificar frutas de maneira distintas dentro de imagens com mais de uma fruta, a fim de dizer separadamente quais estão frescas e quais estão podres.

10. Links

Link Google Colab

- Google Colab: [Modelo Fresh-Rotten | Google Colab](#)

Link Dataset Kaggle: Augmented Dataset for Fruits (Rotten/Fresh)

- Kaggle: [Augmented Dataset for Fruits \(Rotten/Fresh\)](#)

Link GitHub (repositório do projeto)

- GitHub: [Repositório no GitHub](#)